Convolutional Neural Networks

Thomas Ranvier

Université Claude Bernard, Lyon 1

Sommaire

Introduction

Convolutional Neural Networks

La vision par ordinateur

Pourquoi ?

On souhaite permettre à un ordinateur de voir et comprendre des images pour être ensuite capable de réaliser différentes tâches

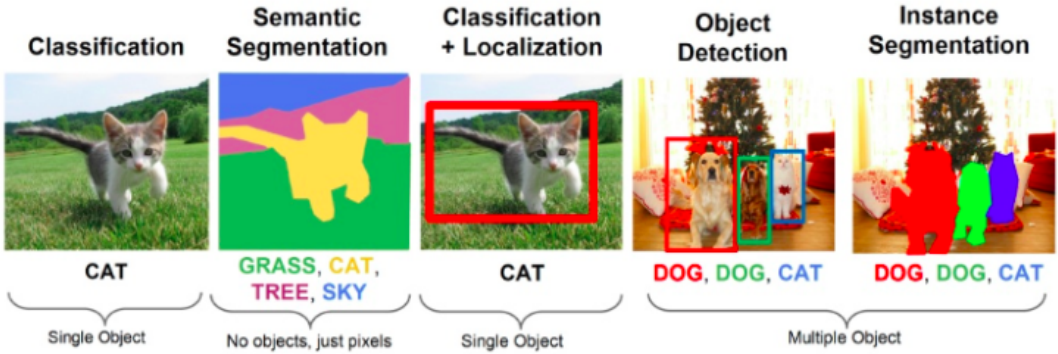

Apprendre automatiquement les features à partir d'images

Objectif

On souhaite que le modèle soit capable d'apprendre les features définissant des objets de lui-même, sans que l'on ait besoin de les définir manuellement

Low level features

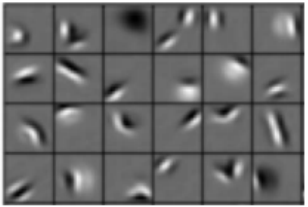

Edges, dark spots

Mid level features

Eyes, ears, nose

High level features

Facial structure

Représentation numérique d'une image

Représentation numérique

- Les images sont constitués d'un ensemble de pixel organisés sur une grille 2D : $(1920, 1080)$

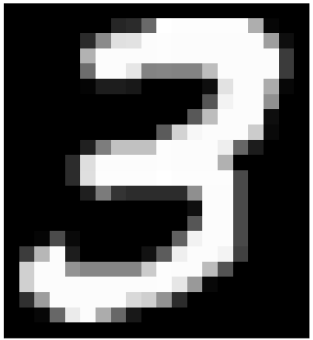

Représentation numérique d'une image

Représentation numérique

- Les images sont constitués d'un ensemble de pixel organisés sur une grille 2D : $(1920, 1080)$
- Chaque pixel est associé à une valeur entre 0 et 255

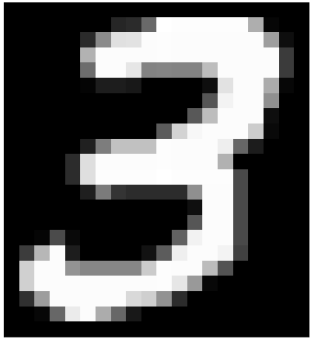

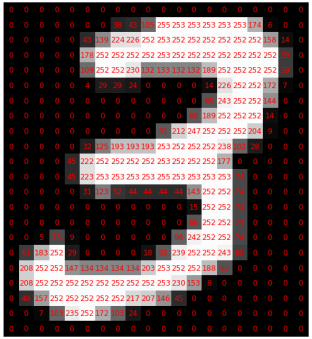

Représentation numérique d'une image

Représentation numérique

- Les images sont constitués d'un ensemble de pixel organisés sur une grille 2D : $(1920, 1080)$
- Chaque pixel est associé à une valeur entre 0 et 255
- Les pixels d'images en couleurs ont 3 valeurs, 1 pour chaque channel de RGB : $(1920, 1080, 3)$

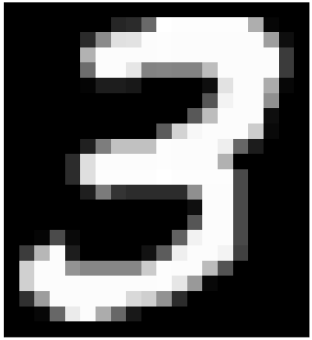

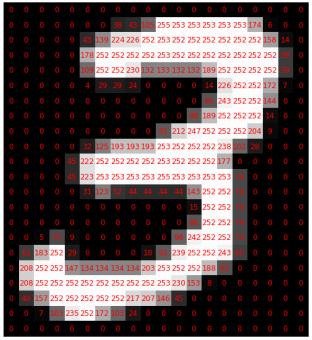

0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	38	43	105	255	253	253	253	253	253	174	6	0
0	0	0	0	0	43	139	224	226	252	253	252	252	252	252	252	252	158	14	0
0	0	0	0	0	178	252	252	252	252	253	252	252	252	252	252	252	252	59	0
0	0	0	0	0	109	252	252	230	132	133	132	132	189	252	252	252	252	59	0
0	0	0	0	0	4	29	29	24	0	0	0	0	14	226	252	252	172	7	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	85	243	252	252	144	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	88	189	252	252	252	14
0	0	0	0	0	0	0	0	0	0	0	0	0	0	91	212	247	252	252	204
0	0	0	0	0	32	125	193	193	193	253	252	252	252	238	102	28	0	0	0
0	0	0	0	0	45	222	252	252	252	253	252	252	252	177	0	0	0	0	0
0	0	0	0	0	45	223	253	253	253	253	255	253	253	253	74	0	0	0	0
0	0	0	0	0	31	123	52	44	44	44	44	143	252	252	74	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	15	252	252	74	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	86	252	252	74	0	0	0	0
0	0	5	75	9	0	0	0	0	0	0	98	242	252	252	74	0	0	0	0
0	61	183	252	29	0	0	0	0	18	92	239	252	252	243	65	0	0	0	0
0	208	252	252	147	134	134	134	134	203	253	252	252	188	83	0	0	0	0	0
0	208	252	252	252	252	252	252	252	252	253	230	153	8	0	0	0	0	0	0
0	49	157	252	252	252	252	252	217	207	146	45	0	0	0	0	0	0	0	0
0	0	7	103	235	252	172	103	24	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

Vision par ordinateur avec un MLP

Désavantages d'un MLP pour le traitement d'images

- Perte de l'information spatiale 2D

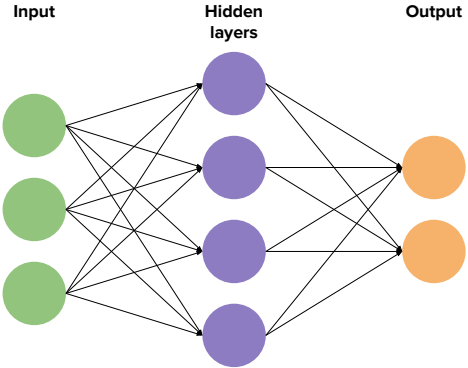

Vision par ordinateur avec un MLP

Désavantages d'un MLP pour le traitement d'images

- Perte de l'information spatiale 2D
- Quantité énorme de paramètres, chaque neurone de la première couche est relié à chaque pixel

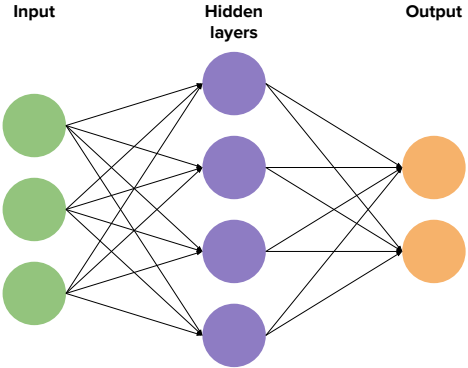

Intuition d'une convolution

- Définir un neurone comme une fenêtre opérant sur une partie de l'image

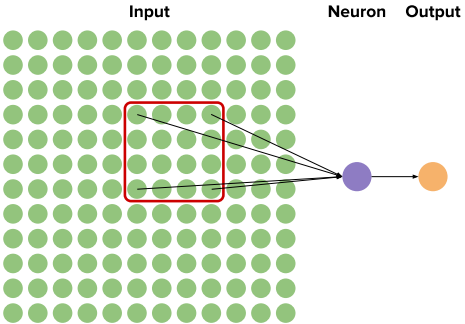

Vision par ordinateur avec un modèle spécialisé pour le traitement d'image

Intuition d'une convolution

- Définir un neurone comme une fenêtre opérant sur une partie de l'image
- Faire parcourir la fenêtre glissante sur l'ensemble de l'image pour générer une feature map

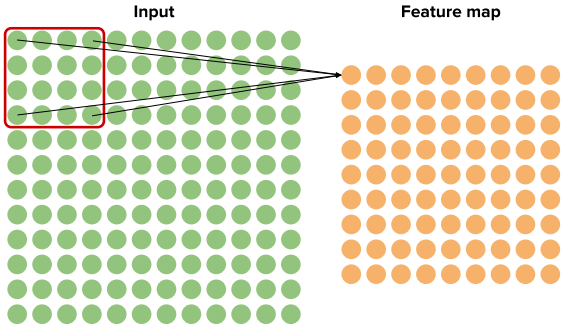

Vision par ordinateur avec un modèle spécialisé pour le traitement d'image

Intuition d'une convolution

- Définir un neurone comme une fenêtre opérant sur une partie de l'image
- Faire parcourir la fenêtre glissante sur l'ensemble de l'image pour générer une feature map
- Utiliser n neurones pour générer une feature map de profondeur n (on parlera de n "channels")

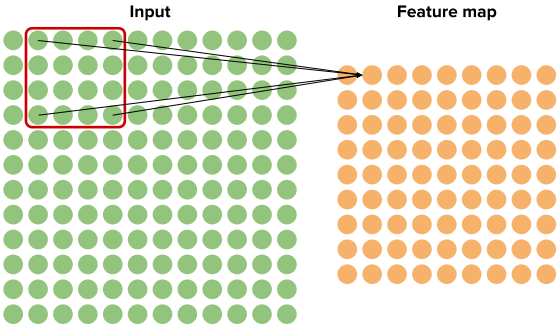

Convolution

L'opération de convolution

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"

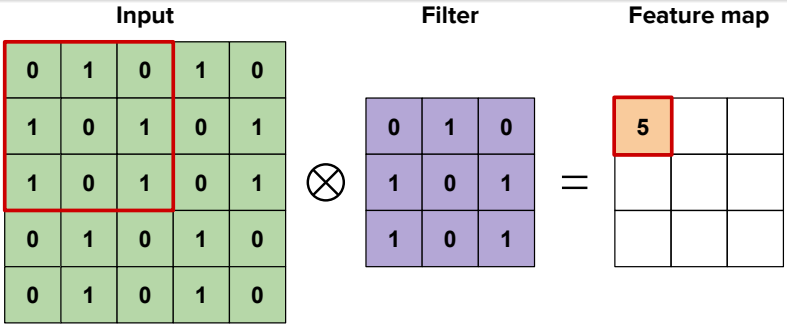

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"

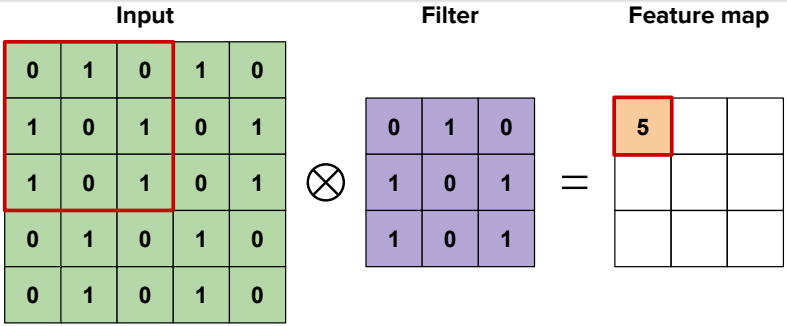

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre

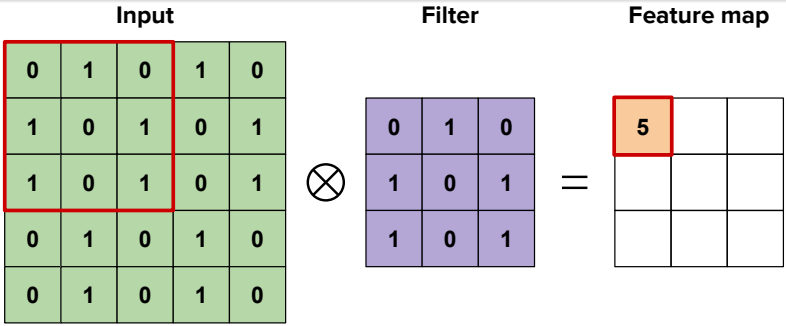

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

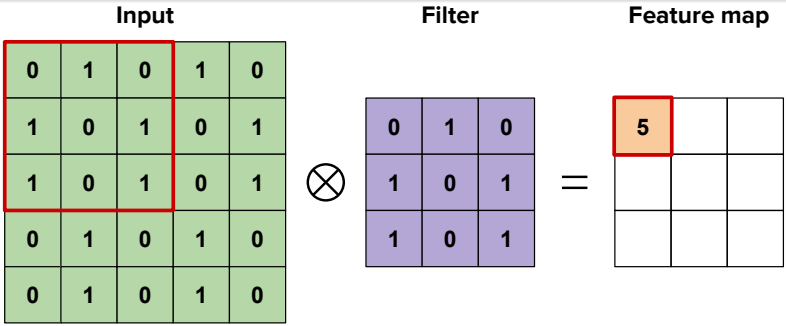

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

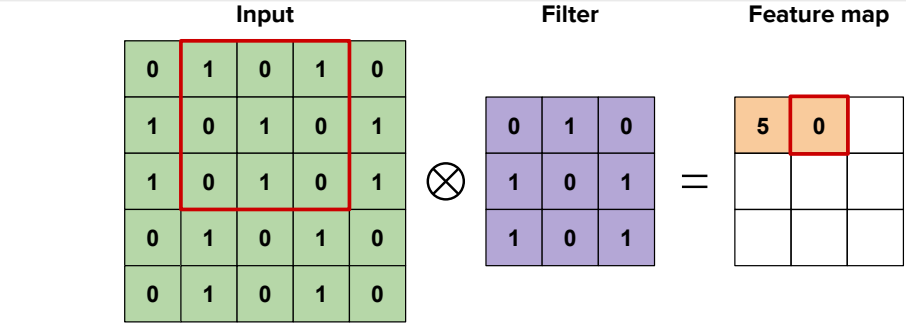

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

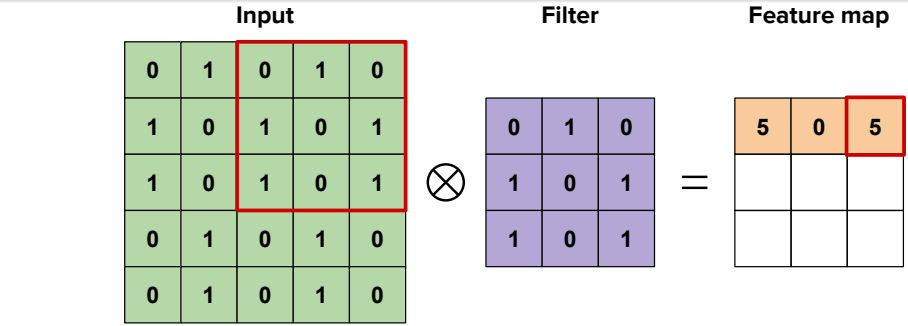

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

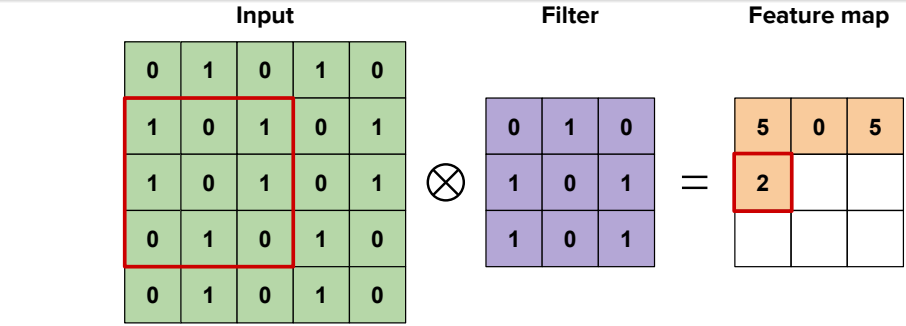

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

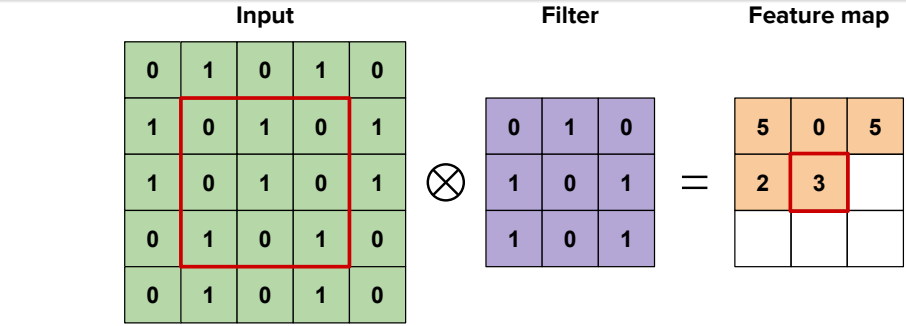

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

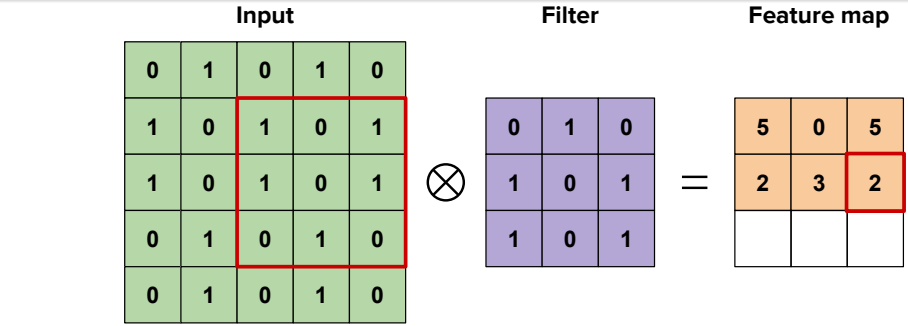

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

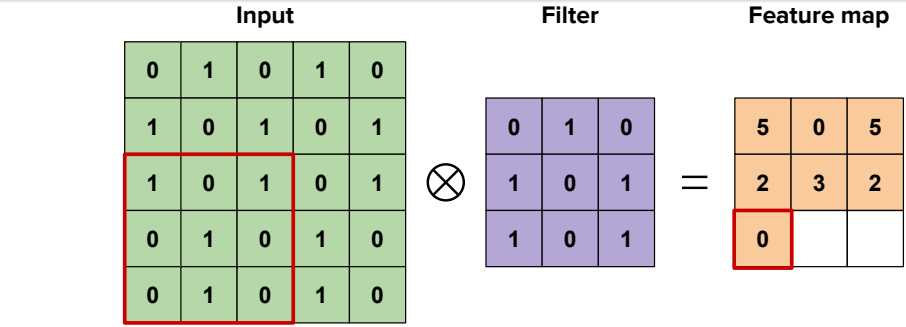

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

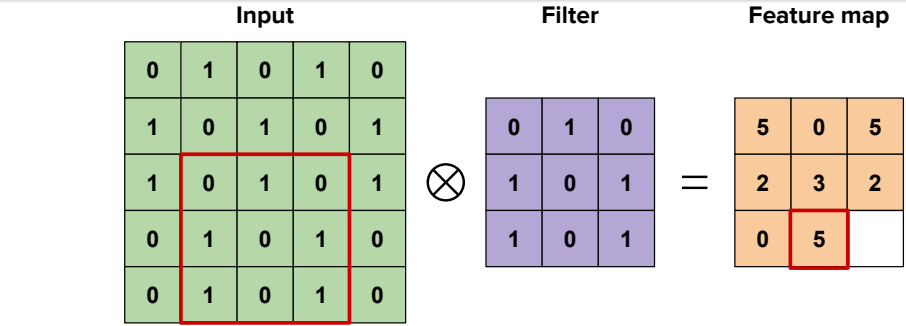

Intuition derrière une convolution

Intuition derrière une convolution

- On appelle les neurones d'une couche de convolution des "filtres"
- Les filtres se déplacent de gauche à droite et haut en bas selon un pas que l'on appelle "strides"
- Un filtre fait la somme du produit Hadamard entre les valeurs d'input et les valeurs du filtre
- On appelle l'output d'une couche à convolutions une "feature map"

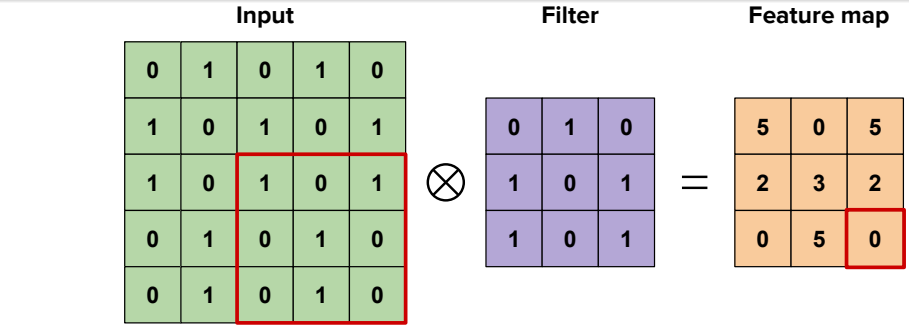

Le padding

L'intérêt du padding

On ajoute des "pixels" à 0 sur les contours de l'image, cela permet de ne pas perdre l'information sur les bords

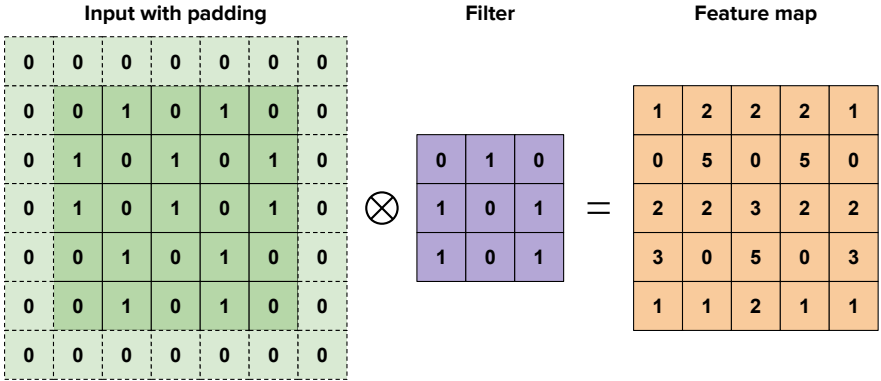

Le padding

Calculer la taille de l'output

La taille de la feature map obtenue en sortie peut être calculée avec la formule suivante :

$$O = \frac{I - K + 2P}{S} + 1$$

Avec :

- I = Taille de l'input
- K = Taille du filtre (aussi appelé kernel)
- P = Taille du padding
- S = Strides

Intérêt des convolutions

Intérêt des convolutions

- Le but de chaque filtre de convolution est d'extraire une feature spécifique de l'image

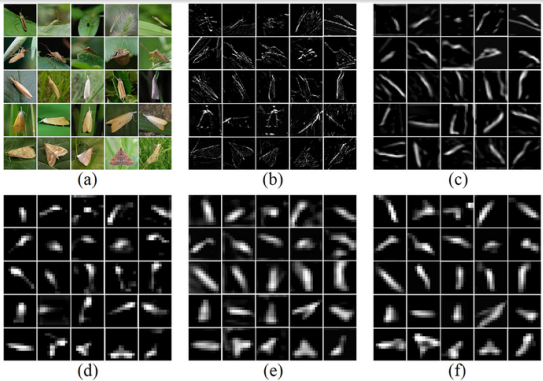

Intérêt des convolutions

Intérêt des convolutions

- Le but de chaque filtre de convolution est d'extraire une feature spécifique de l'image
- Un modèle à convolutions enchaîne les couches à convolutions pour extraire des features à différents niveaux d'abstractions

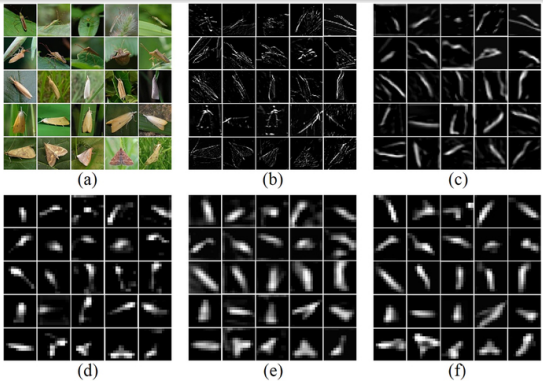

Architecture d'un CNN

Blocs utilisables pour construire un modèle à convolutions

Architecture type d'un CNN pour une tâche de classification

Couches

1. Convolution : Extrait des features à partir de l'input donné

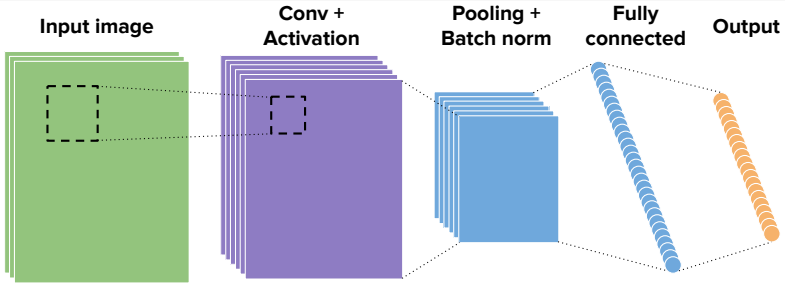

Architecture type d'un CNN pour une tâche de classification

Couches

1. Convolution : Extrait des features à partir de l'input donné
2. Activation : Utilisation d'une non-linéarité après chaque couche de convolutions

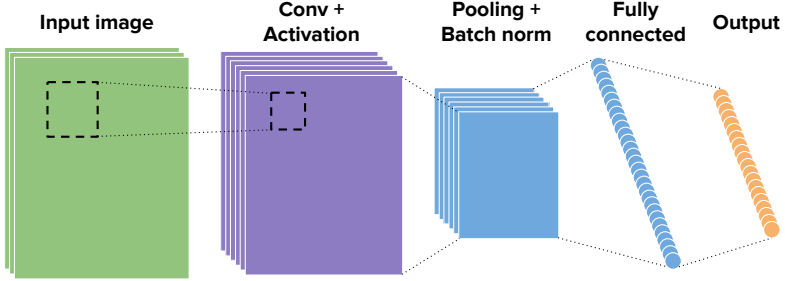

Architecture type d'un CNN pour une tâche de classification

Couches

1. Convolution : Extrait des features à partir de l'input donné
2. Activation : Utilisation d'une non-linéarité après chaque couche de convolutions
3. Pooling : Réduit la taille de l'input

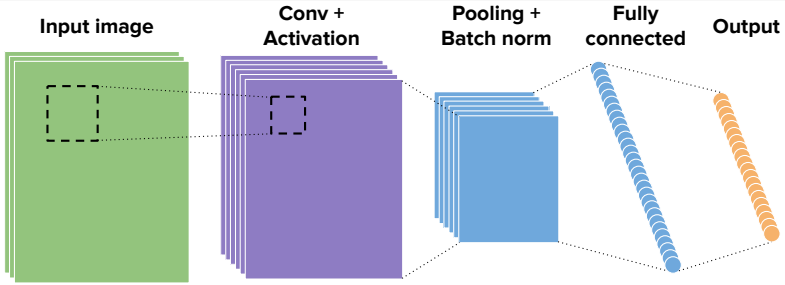

Architecture type d'un CNN pour une tâche de classification

Couches

1. Convolution : Extrait des features à partir de l'input donné
2. Activation : Utilisation d'une non-linéarité après chaque couche de convolutions
3. Pooling : Réduit la taille de l'input
4. Batch norm : Normalise les données, généralement entre la partie conv et celle fully-connected

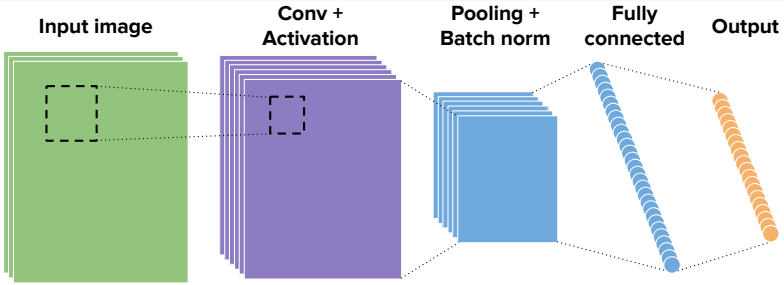

Architecture type d'un CNN pour une tâche de classification

Couches

1. Convolution : Extrait des features à partir de l'input donné
2. Activation : Utilisation d'une non-linéarité après chaque couche de convolutions
3. Pooling : Réduit la taille de l'input
4. Batch norm : Normalise les données, généralement entre la partie conv et celle fully-connected
5. Fully-connected : Utilise les features extraites par les convolutions pour classifier les données

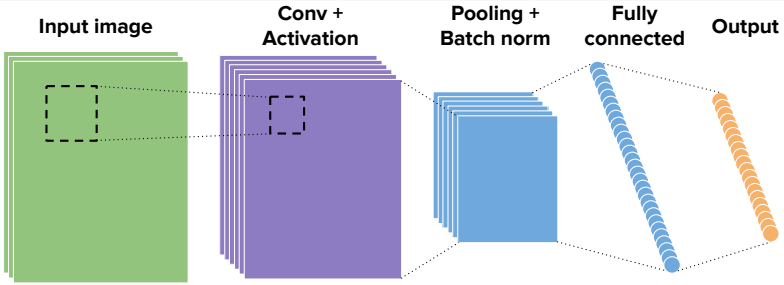

Convolutions avec Keras

Conv2D

```
tf.keras.layers.Conv2D(filters, kernel_size, strides=(1, 1), padding="valid", activation=None)
```

- filters : Nombre de filtres à créer, correspondra à la profondeur de la feature map générée

Convolutions avec Keras

Conv2D

```
tf.keras.layers.Conv2D(filters, kernel_size, strides=(1, 1), padding="valid", activation=None)
```

- filters : Nombre de filtres à créer, correspondra à la profondeur de la feature map générée
- kernel_size : Dimensions des filtres

Convolutions avec Keras

Conv2D

```
tf.keras.layers.Conv2D(filters, kernel_size, strides=(1, 1), padding="valid", activation=None)
```

- filters : Nombre de filtres à créer, correspondra à la profondeur de la feature map générée
- kernel_size : Dimensions des filtres
- strides : Pas de déplacement des filtres sur l'input

Convolutions avec Keras

Conv2D

```
tf.keras.layers.Conv2D(filters, kernel_size, strides=(1, 1), padding="valid", activation=None)
```

- filters : Nombre de filtres à créer, correspondra à la profondeur de la feature map générée
- kernel_size : Dimensions des filtres
- strides : Pas de déplacement des filtres sur l'input
- padding : "valid" n'applique pas de padding, "same" génère un padding tel que l'output ait les mêmes dimensions que l'input

Convolutions avec Keras

Conv2D

```
tf.keras.layers.Conv2D(filters, kernel_size, strides=(1, 1), padding="valid", activation=None)
```

- filters : Nombre de filtres à créer, correspondra à la profondeur de la feature map générée
- kernel_size : Dimensions des filtres
- strides : Pas de déplacement des filtres sur l'input
- padding : "valid" n'applique pas de padding, "same" génère un padding tel que l'output ait les mêmes dimensions que l'input
- activation : La non-linéarité à appliquer après la couche de convolutions

Pooling

Pooling

Les 2 principaux types de pooling utilisés sont les Max et Average poolings :

1. `tf.keras.layers.MaxPooling2D(pool_size=(2, 2))`

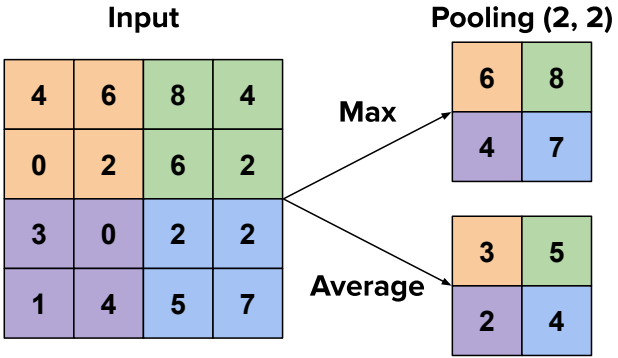

Pooling

Pooling

Les 2 principaux types de pooling utilisés sont les Max et Average poolings :

1. `tf.keras.layers.MaxPooling2D(pool_size=(2, 2))`
2. `tf.keras.layers.AveragePooling2D(pool_size=(2, 2))`

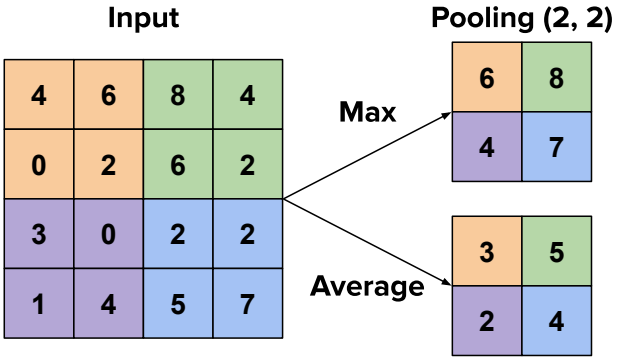

Exemple d'architecture en pratique

Architecture de modèle à convolutions sous Keras

```
model = tf.keras.Sequential([
    # First conv layer
    tf.keras.layers.Conv2D(32, 5, strides=1, padding='same', activation='relu'),
    tf.keras.layers.MaxPool2D(pool_size=(2,2)),

    # Second conv layer
    tf.keras.layers.Conv2D(64, 3, strides=1, padding='same', activation='relu'),
    tf.keras.layers.MaxPool2D(pool_size=(2,2)),

    # Batch norm for stabilization
    tf.keras.layers.BatchNormalization(),

    # Flatten data into a vector for the fully-connected part
    tf.keras.layers.Flatten(),

    tf.keras.layers.Dense(units=128, activation='relu'),
    tf.keras.layers.Dense(units=10, activation='softmax')
])
```

Applications

Applications réelles de CNN

Détection d'objets

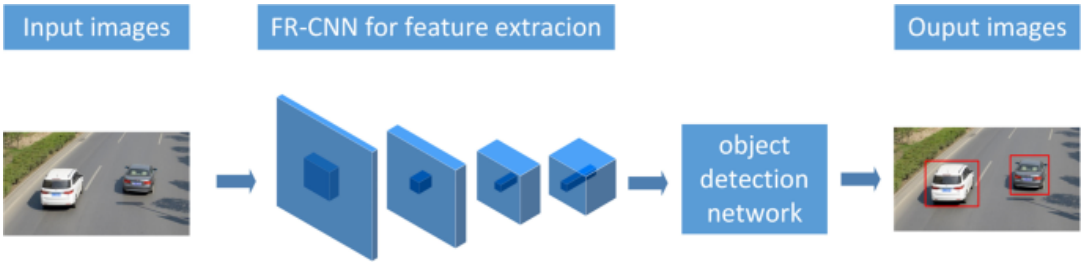

Voiture autonome

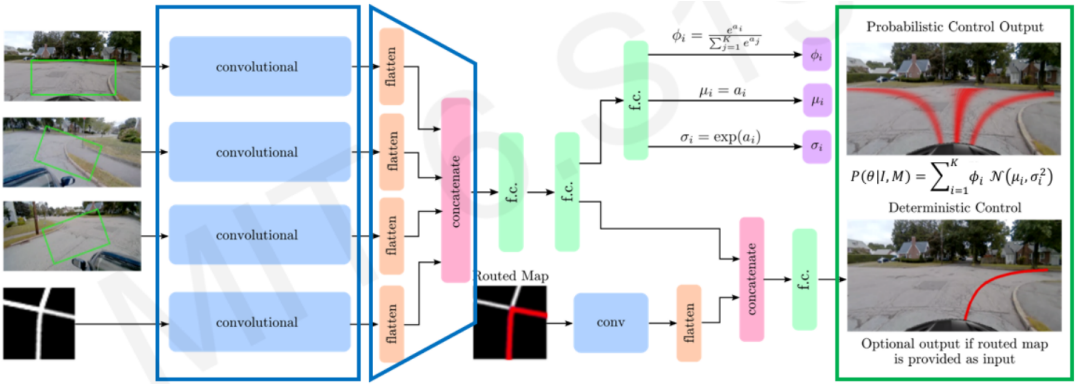

Imagerie médicale

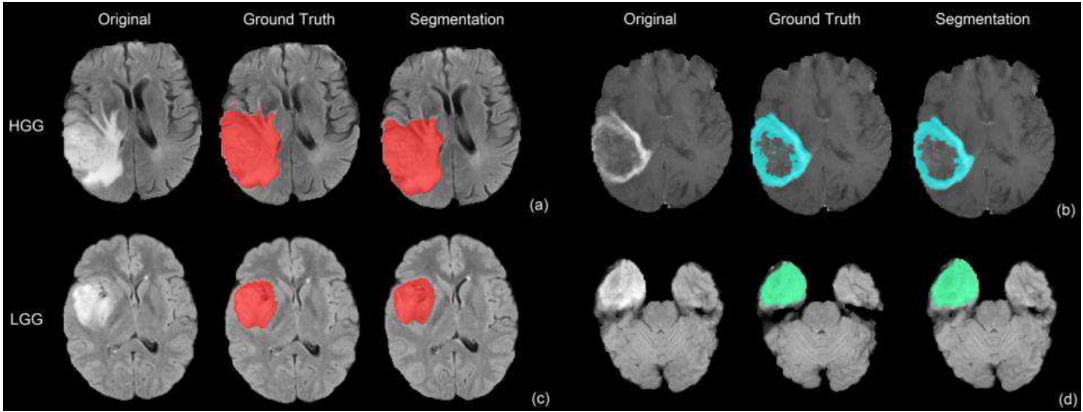

Segmentation

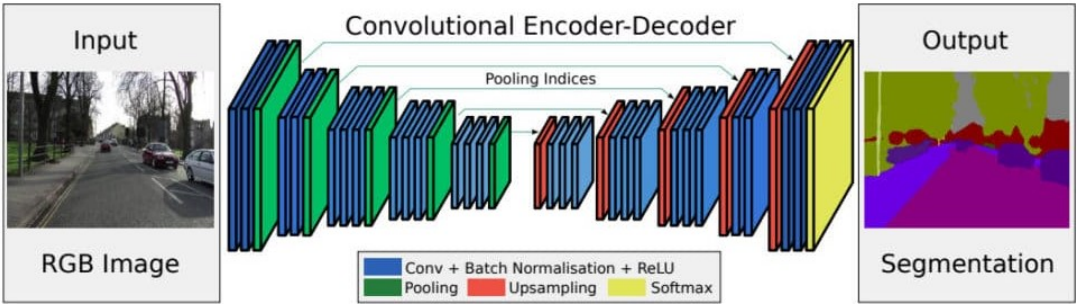

Transfert de style